



OpenMP (OMP): Introdução e Primeiros Programas

Paulo Sérgio Lopes de Souza pssouza@icmc.usp.br

Universidade de São Paulo / ICMC / SSC — São Carlos Laboratório de Sistemas Distribuídos e Programação Concorrente









OMP: Introdução

- O que é o OpenMP?
 - Open-Multi-Processing (OMP)
 - Especificação (API) para um conjunto de diretivas de compilação, funções e variáveis de ambiente
 - Lembrando diretivas
 - Em C: #include, #define, #ifdef, #endif, ...
 - Em Fortran: \$omp
 - Lembrando variáveis de ambiente
 - Variáveis definidas no ambiente de execução de um processo
 - Passadas aos processos por herança, vindas do processo pai, normalmente o shell.
 - Ex: \$PATH no Linux e %CD% no Windows, ...
 - OMP permite determinar paralelismo de alto nível em programas Fortran C C++
 - Aplicações multi-threaded e com memória compartilhada

OMP: Introdução

- Qual o problema que o OMP resolve?
 - Paralelizar um programa requer programador procure por porções paralelas/independentes
 - Muitas vezes o foco é distribuir a computação de loops aninhados aos elementos de processamento (processadores/núcleos)
 - Computações necessitam trocar dados, que podem vir de uma mem compartilhada
 - Requer sincronização para garantir semântica
 - Processadores são assíncronos: sincronização cabe ao software
 - Fabricantes de SMPs na década de 80
 - Desenvolveram notações específicas para paralelização de alto nível
 - Como dividir a carga de trabalho & como sincronizar a computação
 - Surgiram novas funções e diretivas de compilação para Fortran
 - Compilador usava essas informações/recursos para paralelizar o código
 - Funcionava, mas faltava portabilidade entre plataformas diferentes
 - OpenMP ARB (OpenMP Architecture Review Board)
 - Definiu o OpenMP para solucionar o problema de portabilidade em 1997
 - Especificação 5.0 do OMP é de novembro de 2018

OMP: Quem e Quando

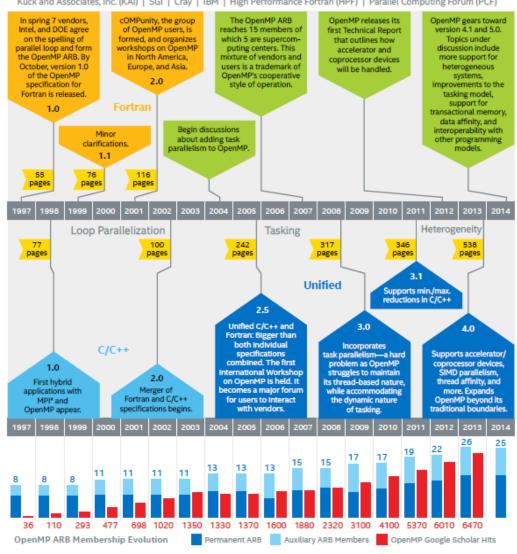
- Membros OpenMP ARB:
 - Compac/Digital
 - HP
 - Intel
 - IBM
 - Kuck & Associates, Inc (KAI)
 - Silicon Graphics, Inc.
 - Sun Microsystems, Inc.
 - US Dept of Energy ASCI Prog
- Desenvolvedores de Aplicativos
 - MACROS
 - Automação industrial
 - GenASiS
 - Gen Astrophysical Sim Syst
 - Altair RADIOSS
 - Análise de impacto e crash-test
 - Altair OptiStruct
 - Durabilidade, vibração, ...
 - MATLAB NaN e TSA toolboxes
 - Machine learning, estat.

An OpenMP* Timeline

By Jim Cownie, OpenMP Architect, Alejandro Duran, Application Engineer, Michael Klemm, Senior Application Engineer, and Luke Lin, OpenMP Software Product Manager

1996 Vendors provide similar but different solutions for loop <u>parallelism</u>, causing portability and maintenance problems.

Kuck and Associates, Inc. (KAI) | SGI | Cray | IBM | High Performance Fortran (HPF) | Parallel Computing Forum (PCF)



٠...

OMP: Alinhando Expectativas

O que o OMP não faz ...

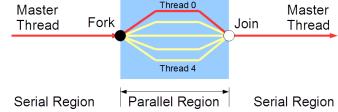
- Atuar em sistemas paralelos com memória distribuída
- Ter implementações idênticas
- Garantir o uso mais eficiente da memória compartilhada
- Verificar dependências de dados, conflitos de dados, condições de disputa ou deadlocks
- Verificar códigos que não se adequam ao paralelismo pretendido
- Usar a paralelização automática gerada pelo compilador
 - flags de compilação
- Garantir entrada e saída síncrona para o mesmo arquivo pelas threads paralelas

Algumas metas do OMP

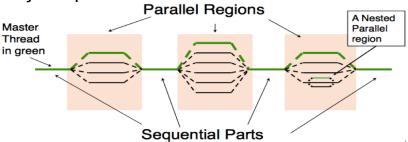
- Oferecer portabilidade para várias plataformas MIMD com memória compartilhada
 - C, C++ e Fortran
- Padrão simplificado com o uso de poucas diretivas
- Fácil de usar em um paralelismo incremental sobre o código com granulação grossa ou fina
- Fórum público para a API e participação de membros da academia, indústria e desenvolvedores

OMP: Modelo de Programação

- Identificação explícita do paralelismo
 - OMP oferece controle da paralelização ao programador
 - Baseado em diretivas de compilação
- Usa o modelo de execução paralela FORK-JOIN
 - Programas OMP iniciam com uma thread mestre (região sequencial)
 - executa sequencialmente até a primeira diretiva para criar uma região paralela
 - A thread mestre criar um time (team) de threads paralelas (FORK)
 - Instruções nessas threads são executadas em paralelo (região paralela)
 - Há uma sincronização no final das execuções das threads paralelas, incluindo a thread mestre (JOIN)
 - Apenas a thread mestre continua executando
 - Nova região sequencial



- Permite paralelismo aninhado (nested parallelism)
 - Construções paralelas dentro de outras construções paralelas



OMP: Modelo de Programação

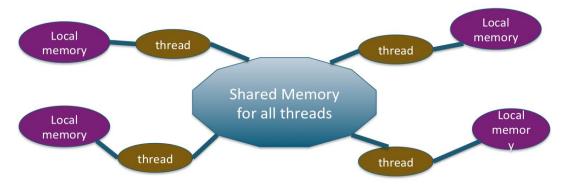
• Uma comparação com o modelo de programação *Pthreads*

Figure 7.4. A sample OpenMP program along with its Pthreads translation that might be performed by an OpenMP compiler.

```
int a, b;
main()
    // serial segment
    #pragma omp parallel num threads (8) private (a) shared (b)
           parallel segment
      rest of serial segment
                                            Sample OpenMP program
                       int a, b;
                       main()
                               serial segment
                           for (i = 0; i < 8; i++)
                 Code
                                pthread create (....., internal thread fn name, ...);
             inserted by
            the OpenMP
                            for (i = 0; i < 8; i++)
              compiler
                                pthread join (.....);
                            / rest of serial segment
                       void *internal thread fn name (void *packaged argument) [
                            int a:
                           // parallel segment
                                                              Corresponding Pthreads translation
```

OMP: Modelo de Memória

- Memória Compartilhada com paralelismo de threads
 - Memória global compartilhada (precisa proteger regiões críticas)
 - Memória local não compartilhada entre as threads



- Consistência de Memória Relaxada e visão temporária da memória da thread
 - Threads armazenam seus dados em cache
 - Não mantêm consistência estrita com a memória física todo o tempo
- Quando a consistência é necessária, programador usa a diretiva flush do OMP

OMP: Modelo de E/S

- OMP n\u00e3o especifica como a E/S paralela deve ser feita
 - Se múltiplas threads acessam ao mesmo arquivo
 - Acessos concorrentes podem gerar conflito
 - Programador deve garantir o acesso correto pelas threads
 - Se múltiplas threads acessam arquivos distintos
 - Em tese n\u00e3o deveria haver problema com condi\u00fc\u00fces de disputa nos arquivos

OMP: Estrutura de um programa C

- Incluir header
 - #include <omp.h>
- Diretivas & Cláusulas
 - #pragma omp <directive> [clause list]
 - Diretivas básicas: parallel, for, sections, single, critical, ...
- Funções OMP
 - omp_set_num_theads(), omp_get_num_threads(), omp_get_thread_num(), omp_in_parallel(), omp_get_wtime (),
 - omp_init_lock(), omp_init_net_lock(),
 - omp_set_lock, omp_unset_lock(),
 - omp_set_nest_lock(), omp_unset_nest_lock,
 - omp_test_lock(), omp_test_nest_lock(), ...
- Variáveis de ambiente OMP
 - OMP_NESTED, OMP_NUM_THREADS, OMP_SCHEDULE, ...
- Compilação no Linux com GCC
 - gcc fonte.c –o binary –fopenmp
 - No Linux, basta instalar o pacote de desenvolvimento com o gcc que o OMP vem junto!

OMP: Estrutura de um programa C

- Dicas para programas em C/OpenMP
 - Siga as convenções de diretivas para a linguagem C
 - Case sensitive
 - Cada diretiva refere-se ao comando abaixo dela
 - Esse comando abaixo pode ser um bloco estruturado de comandos
 - Coloque a abertura de bloco "{" na linha abaixo da diretiva; não na mesma linha
 - Linhas de código com diretivas longas (várias cláusulas), podem ser particionadas em várias linhas, desde que use "\"

OMP: Criando Regiões Paralelas

- Diretiva parallel
 - Construtor paralelo fundamental em OMP
 - Permite criar regiões paralelas
 - Times (teams) de threads
 - A thread já existente torna-se a mestre
 - Thread de número zero
 - Threads geradas são numeradas sequencialmente a partir de zero
 - O bloco estruturado de comandos (ou um único comado terminado com ";")
 - Será replicado nas threads geradas
 - Haverá uma barreira implícita no fim do bloco estruturado replicado
 - só a thread mestre continua após o término da região paralela
 - Se uma thread terminar de maneira anormal na região paralela
 - Todas as threads terminam também
 - A situação final da computação feita nas threads é indefinido

```
#pragma omp parallel [clause[ [, ]clause] ...]
    structured-block
clause:
    if(scalar-expression)
    num_threads(integer-expression)
    default(shared | none)
    private(list)
    firstprivate(list)
    shared(list)
    copyin(list)
    reduction(reduction-identifier: list)
    4.0 proc bind(master | close | spread)
```

OMP: Criando Regiões Paralelas

- Principais cláusulas da diretiva parallel:
 - if(scalar-expression)
 - Condiciona criação da região paralela
 - num threads
 - Número de threads para serem geradas.
 - Alternativas:
 - int omp_set_num_threads(int nthreads)
 - OMP NUM THREADS
 - Precedência: if(), num_threads(), fnct, var_amb, padrão da implementação
 - default(shared | none)
 - private(list)
 - firstprivate(list)
 - shared(list)
 - copyin(list)
 - Copia o valor da variável threadprivate na thread mestre para as demais threads
 - Usada em conjunto com a #pragma omp threadprivate(list)
 - reduction(reduction-identifier:list)
 - +, *, -, &, |, ^, &&, ||, max, min

```
#pragma omp parallel [clause[ [, ]clause] ...]
structured-block

clause:
if(scalar-expression)
num_threads(integer-expression)
default(shared | none)
private(list)
firstprivate(list)
shared(list)
copyin(list)
reduction(reduction-identifier: list)
4.0 proc_bind(master | close | spread)
```

OMP: Criando Regiões Paralelas

- Diretivas parallel aninhadas (nested)
 - Novas regiões paralelas podem ser geradas dentro de regiões paralelas
 - O OMP não permite geração de threads aninhadas por padrão
 - Deve-se habilitar regiões paralelas aninhadas usando uma dessas possibilidades
 - Função omp_set_nested() passando TRUE
 - Variável de ambiente OMP_NESTED com TRUE
 - A função omp_get_nested() informa se o aninhamento está habilitado ou não
 - Se o aninhamento n\u00e3o estiver habilitado
 - Uma nova diretiva parallel cria o novo time, composto de apenas uma thread

OMP: Distribuindo a carga de trabalho nas threads

Construtores de compartilhamento de trabalho

- Dividem a carga de trabalho da região paralela pelas *threads*
- Não criam novas threads, usam as já existentes
 - Esses construtores devem pertencer a uma região paralela para usarem múltiplas threads
- Não há uma sincronização no início da execução
 - mas há uma barreira no fim desses construtores
- Todas as threads da região paralela devem encontrar os construtores de compartilhamento (ou nenhuma deve encontrar)
 - Devem encontrá-los na mesma ordem se houver mais deles na região paralela

#pragma omp for [clause[[,]clause] ...]

reduction(reduction-identifier: list) schedule(kind[, chunk size])

for-loops

private(list)

collapse(n)

ordered nowait

firstprivate(list)

lastprivate(list)

clause:

Exemplos de construtores de compartilhamento de trabalho:

- for
 - Compartilha iterações de um loop for (paralelismo de dados)
- sections
 - Divide computações distintas em threads distintas (paralelismo funcional)
- single
 - Indica que o bloco estruturado será executado por uma única thread

OMP: Diretiva For

- Diretiva for
 - Compartilha iterações de um for (paralelismo de dados)
- O for deve estar na forma canônica
 - Perfeitamente aninhados
 - Número de iterações deve ser conhecido antes da execução
 - Número de iterações não pode mudar ao longo da execução
 - Não há sincronizações implícitas entre as iterações
 - Há restrições para expressões de teste e incremento da iteração

Cláusulas:

- collapse
 - Determina quantos loops aninhados devem ser unidos em uma mesma iteração para ser então distribuída entre as threads
 - Execução sequencial das iterações determina a ordem das iterações unidas por collapse
- ordered
 - Especifica que as iterações devem ser executadas na mesma ordem da execução sequencial
- nowait
 - Se presente, as threads não sincronizarão na barreira no fim do for

```
#pragma omp for [clause[ [, ]clause] ...]
    for-loops
clause:
    private(list)
    firstprivate(list)
    lastprivate(list)
    reduction(reduction-identifier: list)
    schedule(kind[, chunk_size])
    collapse(n)
    ordered
    nowait
```

OMP: Escalonamento de Iterações do for às Threads

Escalonamento das iterações do for nas threads

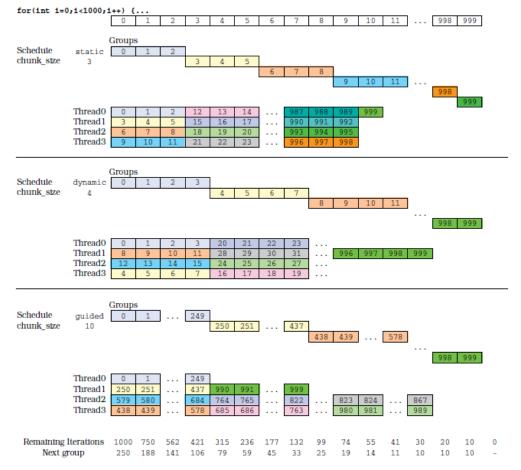


FIGURE 4.7

Examples of resulting iteration partitioning and assignment based on the scheduling scheme for a 1000-iteration for loop. We end up with 334 groups for static, 250 groups for dynamic, and 15 groups for guided scheduling for the given chunk_size parameters. Only for the static scheme do we have *a priori* knowledge of the iteration group assignment to threads.

Static: iterações divididas em porções de chunk_size elementos e atribuídas às threads de maneira Round-Robin. Padrão para chunk_size é **Nr_Iter/Nr_Threads**.

Dynamic: cada thread executa chunk_size iterações e requisita mais até finalizar. Padrão para chunk_size = 1.

Guided: Cada thread executa chunk_size iterações, sendo que a cada novo pedido por requisições, o número de iterações é recalculado usando **Nr_Threads Restantes** / **Nr_Threads**. Chunk_size padrão é 1.

Auto: Decisão pelo escalonamento é feita pelo compilador ou em tempo de execução.

Runtime: Escalonamento decidido pela variável de ambiente.

OMP: Diretiva section

- Diretiva sections
 - Divide computações distintas em threads distintas (paralelismo funcional)

```
#pragma omp sections [clause[ [, ] clause] ...]
                                                    #pragma omp parallel
  [#pragma omp section]
      structured-block
  [#pragma omp section
                                                          #pragma omp sections
structured-block]
                                                                #pragma omp section
clause:
                                                                      taskA();
   private(list)
   firstprivate(list)
                                                                #pragma omp section
   lastprivate(list)
                                         10
   reduction(reduction-identifier: list)
                                                                      taskB();
   nowait
                                         13
                                                                #pragma omp section
                                         14
                                         15
                                                                      taskC();
                                        16
                                        17
                                         18
                                                                          Grama et al. (2003)
```

OMP: Diretiva single

- Diretiva single
 - Indica que o bloco estruturado será executado por uma única thread

```
#pragma omp single [clause[ [, ]clause] ...]
    structured-block
clause:
    private(list)
    firstprivate(list)
    copyprivate(list)
    nowait
```

- Diretiva critical
 - Identifica uma região crítica que precisa ser protegida
 - Código estruturado terá acesso a apenas uma thread por vez #pragma omp critical (name) structured block
 - Argumento (name) é opcional e permite diferenciar regiões críticas
 - Há outras maneiras de proteger regiões críticas:
 - atomic, locks, uso de semáforos de Pthreads, ...
- Diretiva atomic
 - Garante atomicidade a operações de load/store em uma posição de memória
 - x++, ++x, x--, --x, e mais operações binárias com expressões

OMP: Exemplos de Programas

- Hello World
 - Exemplo de uso da diretiva parallel com a cláusula reduction
- Soma Elementos de um Vetor de Números Inteiros
 - Analise a facilidade para o desenvolvimento de código paralelo
 - Veja o desempenho ao usar critical e reduction
- Números perfeitos até N
 - Analise as diferenças de desempenho com escalonamentos diferentes do for
- Multiplicação de Matrizes com a cláusula collapse
 - Veja o impacto no desempenho com o uso de collapse
- O algoritmo exemplo para Nested-Parallel
 - Veja os números das threads
- O algoritmo Nested-Sections exemplifica o paralelismo funcional com aninhamento
 - Verifique os números das threads usadas pelas seções.

Referências



Barlas G.; Multicore and GPU Programming: an integrated approach. Elsevier, 2015.

FOSTER, I. Designing and Building Parallel Programs, Addison-Wesley Publishing Company, 1994.

GRAMA, A.; KUMAR, U.; GUPTA, A.; KARYPIS, G. Introduction to Parallel Computing, 2nd Edition, 2003.

OpenMP API 5.0 C/C++ Syntax Quick Reference Card. 2018. Disponível em https://www.openmp.org/wpcontent/uploads/OpenMPRef-5.0-111802-web.pdf. Último acesso em 28/09/2020.

OpenMP Application Program Inferface, Version 5.0 – 2018, Disponível em https://www.openmp.org/wp-content/uploads/OpenMP-API-Specification-5.0.pdf. Último acesso em 28/09/2020.

Reinders, James (Ed.) The Parallel Universe: flow Graphs, Speculative Locks, and Tasks Arenas. Intel. 2014. Disponível em https://www.openmp.org/about/whos-using-openmp/ Útlimo acesso em 28/09/2020

OpenMP Resources. NERSC Documentation (National Energy Research Scientific Computing Center. Berkeley Lab. Disponível em:

https://docs.nersc.gov/development/programming-models/openmp/openmp-resources/. Último acesso em 28/09/2020.





OpenMP: Introdução e Primeiros Programas

Paulo Sérgio Lopes de Souza pssouza@icmc.usp.br

Universidade de São Paulo / ICMC / SSC - São Carlos Laboratório de Sistemas Distribuídos e Programação Concorrente









